# Kontekstno-neodvisne gramatike za kodiranje in stiskanje podatkov

Janez Podlogar

Univerza v Ljubljani, Fakulteta za matematiko in fiziko

5. 5. 2023

#### Spomnimo se

S kontekstno-neodivsnih gramatik želimo stisniti poljuben niz.

### Spomnimo se

S kontekstno-neodivsnih gramatik želimo stisniti poljuben niz.

#### Definicija

- *Abeceda* je končna neprazna množica  $\Sigma$
- Množica vseh končnih nizov abecede  $\Sigma$  označimo s  $\Sigma^*$
- Dolžina niza w je število znakov abecede v w, označimo z |w|

### Spomnimo se

S kontekstno-neodivsnih gramatik želimo stisniti poljuben niz.

#### Definicija

- *Abeceda* je končna neprazna množica  $\Sigma$
- Množica vseh končnih nizov abecede  $\Sigma$  označimo s  $\Sigma^*$
- Dolžina niza w je število znakov abecede v w, označimo z |w|

#### Primer nizov abecede

Naj bo  $\Sigma = \{a, b, c\}$  abeceda, potem sta niza

 $ab \in \Sigma^*$ , cababcccababcccab  $\in \Sigma^*$ 

#### Definicija

#### Definicija

Kontektsno-neodvisna gramatika je četverica  $G = (V, \Sigma, P, S)$ , kjer je

• V končna množica nekončnih simbolov

#### Definicija

- V končna množica nekončnih simbolov
- abeceda  $\Sigma$  množica končnih simbolov

#### Definicija

- V končna množica nekončnih simbolov
- abeceda  $\Sigma$  množica končnih simbolov
- $P \subseteq V \times (V \cup \Sigma)^*$  celovita relacija

#### Definicija

- V končna množica nekončnih simbolov
- abeceda  $\Sigma$  množica končnih simbolov
- $P \subseteq V \times (V \cup \Sigma)^*$  celovita relacija
- $S \in V$  začetni simbol

#### Definicija

*Kontektsno-neodvisna gramatika* je četverica  $G = (V, \Sigma, P, S)$ , kjer je

- V končna množica nekončnih simbolov
- abeceda  $\Sigma$  množica končnih simbolov
- $P \subseteq V \times (V \cup \Sigma)^*$  celovita relacija
- $S \in V$  začetni simbol

#### Definicija

Jezik kontekstno-neodvisne gramatike G je množica vseh nizov, ki jih lahko izpeljemo z gramatiko G, označimo ga z L(G).

Stiskanje niza w = cababcccababcccab

Stiskanje niza w = cababcccababcccab

Naj bo  $G_w = (V, \Sigma, P, S)$ , kjer je

•  $V = \{S, A, B, C\}$ 

Stiskanje niza w = cababcccababcccab

- $V = \{S, A, B, C\}$
- $\Sigma = \{a, b, c\}$

Stiskanje niza w = cababcccababcccab

- $V = \{S, A, B, C\}$
- $\Sigma = \{a, b, c\}$
- $P = \{S \rightarrow cCCA, A \rightarrow ab, B \rightarrow ccc, C \rightarrow AAB\}$

Stiskanje niza w = cababcccababcccab

- $V = \{S, A, B, C\}$
- $\Sigma = \{a, b, c\}$
- $P = \{S \rightarrow cCCA, A \rightarrow ab, B \rightarrow ccc, C \rightarrow AAB\}$
- $\bullet$  S=S

Stiskanje niza w = cababcccababcccab

- $V = \{S, A, B, C\}$
- $\Sigma = \{a, b, c\}$
- $P = \{S \rightarrow cCCA, A \rightarrow ab, B \rightarrow ccc, C \rightarrow AAB\}$
- $\bullet$  S = S

$$S = cCCA$$

Stiskanje niza w = cababcccababcccab

Naj bo  $G_w = (V, \Sigma, P, S)$ , kjer je

- $V = \{S, A, B, C\}$
- $\Sigma = \{a, b, c\}$
- $P = \{S \rightarrow cCCA, A \rightarrow ab, B \rightarrow ccc, C \rightarrow AAB\}$
- $\bullet$  S=S

 $S = cCCA \xrightarrow{C} cAABAAB$ 

Stiskanje niza w = cababcccababcccab

Naj bo  $G_w = (V, \Sigma, P, S)$ , kjer je

- $V = \{S, A, B, C\}$
- $\Sigma = \{a, b, c\}$
- $P = \{S \rightarrow cCCA, A \rightarrow ab, B \rightarrow ccc, C \rightarrow AAB\}$
- $\bullet$  S=S

 $S = cCCA \xrightarrow{C} cAABAAB \xrightarrow{B} cAAcccAAccc$ 

Stiskanje niza w = cababcccababcccab

Naj bo  $G_w = (V, \Sigma, P, S)$ , kjer je

- $V = \{S, A, B, C\}$
- $\Sigma = \{a, b, c\}$
- $P = \{S \rightarrow cCCA, A \rightarrow ab, B \rightarrow ccc, C \rightarrow AAB\}$
- $\bullet$  S=S

 $S = cCCA \xrightarrow{C} cAABAAB \xrightarrow{B} cAAcccAAccc \xrightarrow{A} cababcccababccc$ 

Stiskanje niza w = cababcccababcccab

Naj bo  $G_w = (V, \Sigma, P, S)$ , kjer je

- $V = \{S, A, B, C\}$
- $\Sigma = \{a, b, c\}$
- $P = \{S \rightarrow cCCA, A \rightarrow ab, B \rightarrow ccc, C \rightarrow AAB\}$
- $\bullet$  S=S

 $S = cCCA \xrightarrow{C} cAABAAB \xrightarrow{B} cAAcccAAccc \xrightarrow{A} cababcccababccc = w$ 

Stiskanje niza w = cababcccababcccab

Naj bo  $G_w = (V, \Sigma, P, S)$ , kjer je

- $V = \{S, A, B, C\}$
- $\Sigma = \{a, b, c\}$
- $P = \{S \rightarrow cCCA, A \rightarrow ab, B \rightarrow ccc, C \rightarrow AAB\}$
- $\bullet$  S=S

 $S = cCCA \xrightarrow{C} cAABAAB \xrightarrow{B} cAAcccAAccc \xrightarrow{A} cababcccababccc = w$  Velja, da je

$$L(G_w) = \{w\}.$$

#### Definicija

Kontekstno-neodvisna gramatika G je deterministična, če vsak nekončen simbol  $A \in V$ , nastopa natanko enkrat kot levi član nekega produkcijskega pravila. Kontekstno-neodvisna gramatika, ki ni deterministična, je nedeterministična.

#### Definicija

Kontekstno-neodvisna gramatika G je deterministična, če vsak nekončen simbol  $A \in V$ , nastopa natanko enkrat kot levi član nekega produkcijskega pravila. Kontekstno-neodvisna gramatika, ki ni deterministična, je nedeterministična.

#### **Trditev**

Naj bo *G* deterministična kontekstno-neodvisna gramatika. Potem je jezik gramatike *G* enojec ali pa prazna množica.

Deterministična kontekstno-neodvisna gramatika z praznim jeziokm Naj bo  $G=(V,\Sigma,P,S)$ , kjer je

Deterministična kontekstno-neodvisna gramatika z praznim jeziokm Naj bo  $G=(V,\Sigma,P,S)$ , kjer je

• 
$$V = \{S\}$$

Deterministična kontekstno-neodvisna gramatika z praznim jeziokm

- $V = \{S\}$
- $\Sigma = \{a\}$

Deterministična kontekstno-neodvisna gramatika z praznim jeziokm

- $V = \{S\}$
- $\Sigma = \{a\}$
- $P = \{S \rightarrow S\}$

Deterministična kontekstno-neodvisna gramatika z praznim jeziokm

- $V = \{S\}$
- $P = \{S \to S\}$
- $\bullet$  S=S

Deterministična kontekstno-neodvisna gramatika z praznim jeziokm

Naj bo  $G = (V, \Sigma, P, S)$ , kjer je

- $V = \{S\}$
- $\Sigma = \{a\}$
- $P = \{S \rightarrow S\}$
- $\circ$  S = S

Gramatika je očitno deterministična in velja  $L(G) = \emptyset$ .

Deterministična kontekstno-neodvisna gramatika z odvečnimi simboli

- $V = \{S, A\}$
- $\Sigma = \{a\}$
- $P = \{S \to a, A \to a\}$
- $\bullet$  S=S

Deterministična kontekstno-neodvisna gramatika z odvečnimi simboli

Naj bo  $G = (V, \Sigma, P, S)$ , kjer je

- $V = \{S, A\}$
- $\Sigma = \{a\}$
- $P = \{S \rightarrow a, A \rightarrow a\}$
- $\circ$  S = S

Gramatika je očitno deterministična in velja L(G) = a.

### Neuporabni simboli in prazen jezik

#### Definicija

Pravimo, da kontekstno-neodvisna gramatika G ne vsebuje neuporabnih simbolov, ko za vsak simbol  $y \in V \cup \Sigma$ ,  $y \neq S$ , obstaja končno mnogo nizov  $\alpha_1, \alpha_2, \ldots, \alpha_n \in (V \cup \Sigma)^*$  tako, da je y vsebovan vsaj v enem izmed nizov in velja

$$S = \alpha_1 \Rightarrow \alpha_2 \Rightarrow \cdots \alpha_n \in L(G)$$
.

### Dopustne gramatike

#### Definicija

Kontekstno-neodvisna gramatika G je dopustna, če je deterministična, ne vsebuje neuporabnih simbolov,  $L(G) \neq \emptyset$  in prazen niz ne nastopa kot desni član kateregakoli produkcijska pravila v P.

### Dopustne gramatike

#### Definicija

Kontekstno-neodvisna gramatika G je dopustna, če je deterministična, ne vsebuje neuporabnih simbolov,  $L(G) \neq \emptyset$  in prazen niz ne nastopa kot desni član kateregakoli produkcijska pravila v P.

#### Posledica

Jezik dopustne kontekstno-neodvisne gramatike je enojec.

Za dopustno gramatiko je dovolj podati produkcijska pravila Podana imamo produckcijska pravila

•  $P = \{A_0 \rightarrow aA_1A_2A_3, A_1 \rightarrow ab, A_2 \rightarrow A_1b, A_3 \rightarrow A_2b\}$ 

Za dopustno gramatiko je dovolj podati produkcijska pravila Podana imamo produckcijska pravila

• 
$$P = \{A_0 \rightarrow aA_1A_2A_3, A_1 \rightarrow ab, A_2 \rightarrow A_1b, A_3 \rightarrow A_2b\}$$

Nekončni simboli gramatike so

$$V = \{A_0, A_1, A_2, A_3\}.$$

Za dopustno gramatiko je dovolj podati produkcijska pravila Podana imamo produckcijska pravila

• 
$$P = \{A_0 \rightarrow aA_1A_2A_3, A_1 \rightarrow ab, A_2 \rightarrow A_1b, A_3 \rightarrow A_2b\}$$

Nekončni simboli gramatike so

$$V = \{A_0, A_1, A_2, A_3\}.$$

Končni simboli gramatike so

$$\Sigma = \{a, b\}.$$

Za dopustno gramatiko je dovolj podati produkcijska pravila Podana imamo produckcijska pravila

• 
$$P = \{A_0 \rightarrow aA_1A_2A_3, A_1 \rightarrow ab, A_2 \rightarrow A_1b, A_3 \rightarrow A_2b\}$$

Nekončni simboli gramatike so

$$V = \{A_0, A_1, A_2, A_3\}.$$

Končni simboli gramatike so

$$\Sigma = \{a, b\}.$$

Začetni simbol je

$$S = A_0$$
.

# Endomorfiem

#### Definicija

Naj bo  $\Sigma$  abeceda. *Endomorfizem množice*  $\Sigma^*$  je preslikava  $f \colon \Sigma^* \to \Sigma^*$  tako, da je

$$f(\varepsilon) = \varepsilon \text{ in } \forall w, u \in \Sigma^* : f(wu) = f(w)f(u).$$

# Endomorfiem

## Definicija

Naj bo  $\Sigma$  abeceda. *Endomorfizem množice*  $\Sigma^*$  je preslikava  $f\colon \Sigma^* \to \Sigma^*$  tako, da je

$$f(\varepsilon) = \varepsilon \text{ in } \forall w, u \in \Sigma^* : f(wu) = f(w)f(u).$$

Za endomorfizem f množice  $\Sigma^*$  induktivno definiramo

$$f^{0}(w) = w,$$
  
 $f^{1}(w) = f(w),$   
 $f^{k}(w) = f(f^{k-1}(w)),$ 

kjer je  $w \in \Sigma^*$  in  $k \ge 2$  celo število.

# Definicija

 $D0L\,sistem$ je trojica  $D=(\Sigma,\,f,\,w)$ , kjer je

# Definicija

D0L sistem je trojica  $D = (\Sigma, f, w)$ , kjer je

 $\bullet$   $\Sigma$  abeceda

## Definicija

D0L sistem je trojica  $D = (\Sigma, f, w)$ , kjer je

- $\Sigma$  abeceda
- ullet f endomorfizem množice  $\Sigma^*$

# Definicija

D0L sistem je trojica  $D = (\Sigma, f, w)$ , kjer je

- $\Sigma$  abeceda
- ullet f endomorfizem množice  $\Sigma^*$
- $w \in \Sigma^*$  aksiom

## Definicija

D0L sistem je trojica  $D = (\Sigma, f, w)$ , kjer je

- $\bullet$   $\Sigma$  abeceda
- f endomorfizem množice  $\Sigma^*$
- $w \in \Sigma^*$  aksiom

Sistem generira zaporedje nizov  $\{f^k(w)\mid k=0,1,2\ldots\}$ , ki ima fiksno točko  $w^*$ , če velja

$$w^* \in \{ f^k(w) \mid k = 0, 1, 2 \dots \},$$
  
 $f(w^*) = w^*.$ 

#### Definicija

Naj bo G deterministična kontekstno-neodvisna gramatika v kateri prazen niz ne nastopa kot desni član kateregakoli produkcijska pravila. Na  $(V \cup \Sigma)^*$  definiramo endomorfizem  $f_G$  tako, da

$$\forall a \in \Sigma : f_G(a) = a;$$

če je  $A \to \alpha$  produkcijsko pravilo, potem je  $f_G(A) = \alpha$ .

## Definicija

Naj bo G deterministična kontekstno-neodvisna gramatika v kateri prazen niz ne nastopa kot desni član kateregakoli produkcijska pravila. Na  $(V \cup \Sigma)^*$  definiramo endomorfizem  $f_G$  tako, da

$$\forall a \in \Sigma : f_G(a) = a;$$

če je  $A \to \alpha$  produkcijsko pravilo, potem je  $f_G(A) = \alpha$ .

D0L sistem  $(V \cup \Sigma, f_G, S)$  označimo z D(G) in ga imenujemo D0L sistem prirejen gramatiki G.

#### **Izrek**

Naj bo G dopustna kontekstno-neodvisna gramatika. Potem jezik gramatike G ustreza fiksni točki D0L sistema  $(V \cup \Sigma, f_G, S)$ .

#### **Izrek**

Naj bo G dopustna kontekstno-neodvisna gramatika. Potem jezik gramatike G ustreza fiksni točki D0L sistema  $(V \cup \Sigma, f_G, S)$ .

#### Posledica

Jezik dopustne kontekstno-neodvisna gramatike G je

$$L(G) = \{ f_G^{|V|}(S) \}.$$

# Karakterizacija dopustnih gramatik preko D0L sistema

#### **Izrek**

Naj bo G kontekstno-neodvisna gramatika v kateri prazen niz ne nastopa kot desni član kateregakoli produkcijska pravila. Gramatika G je dopustna natanko takrat, ko je  $f_G^{|V|}(S) \in \Sigma^+$  in vsak simbol iz  $V \cup \Sigma$  nastopa v vsaj enem izmed nizov  $f_G^i(S)$ , kjer je  $i=0,1,\ldots,|V|$ .

• 
$$P = \{A_0 \rightarrow aA_1A_2A_3, A_1 \rightarrow ab, A_2 \rightarrow A_1b, A_3 \rightarrow A_2b\}$$

• 
$$P = \{A_0 \rightarrow aA_1A_2A_3, A_1 \rightarrow ab, A_2 \rightarrow A_1b, A_3 \rightarrow A_2b\}$$

• 
$$V = \{A_0, A_1, A_2, A_3\}$$
 in  $\Sigma = \{a, b\}$ 

- $P = \{A_0 \rightarrow aA_1A_2A_3, A_1 \rightarrow ab, A_2 \rightarrow A_1b, A_3 \rightarrow A_2b\}$
- $V = \{A_0, A_1, A_2, A_3\}$  in  $\Sigma = \{a, b\}$

$$f_G(A_0) = aA_1A_2A_3$$

- $P = \{A_0 \rightarrow aA_1A_2A_3, A_1 \rightarrow ab, A_2 \rightarrow A_1b, A_3 \rightarrow A_2b\}$
- $V = \{A_0, A_1, A_2, A_3\}$  in  $\Sigma = \{a, b\}$

$$f_G(A_0) = aA_1A_2A_3$$

$$f_G^2(A_0) = aabA_1bA_2b$$

- $P = \{A_0 \rightarrow aA_1A_2A_3, A_1 \rightarrow ab, A_2 \rightarrow A_1b, A_3 \rightarrow A_2b\}$
- $V = \{A_0, A_1, A_2, A_3\}$  in  $\Sigma = \{a, b\}$

$$f_G(A_0) = aA_1A_2A_3$$

$$f_G^2(A_0) = aabA_1bA_2b$$

$$f_G^3(A_0) = aababbA_1bb$$

$$f_G^4(A_0) = aababbabbb$$

- $P = \{A_0 \rightarrow aA_1A_2A_3, A_1 \rightarrow ab, A_2 \rightarrow A_1b, A_3 \rightarrow A_2b\}$
- $V = \{A_0, A_1, A_2, A_3\}$  in  $\Sigma = \{a, b\}$

$$f_G(A_0) = aA_1A_2A_3$$

$$f_G^2(A_0) = aabA_1bA_2b$$

$$f_G^3(A_0) = aababbA_1bb$$

$$f_G^4(A_0) = aababbabbb$$

Vsak od simbolov  $A_1, A_2, A_3, a, b$  se pojavi vsaj enkrat v zgoraj izračunanih nizih

- $P = \{A_0 \rightarrow aA_1A_2A_3, A_1 \rightarrow ab, A_2 \rightarrow A_1b, A_3 \rightarrow A_2b\}$
- $V = \{A_0, A_1, A_2, A_3\}$  in  $\Sigma = \{a, b\}$

$$f_G(A_0) = aA_1A_2A_3$$

$$f_G^2(A_0) = aabA_1bA_2b$$

$$f_G^3(A_0) = aababbA_1bb$$

$$f_G^4(A_0) = aababbabbb$$

Vsak od simbolov  $A_1, A_2, A_3, a, b$  se pojavi vsaj enkrat v zgoraj izračunanih nizih in  $f_G^4(A_0) \in \Sigma^+$ .

# Posplošitev izreka

#### **Izrek**

Naj bo G dopustna kontekstno-neodvisna gramatika in naj bo  $\alpha \in (V \cup \Sigma)^+$ . Potem ima D0L sistem  $(V \cup \Sigma, f_g, \alpha)$  fiksno točko  $w^* \in \Sigma^+$ . in velja formula

$$w^* = f_G^{|V|}(\alpha).$$

# Uporaben endomorfizem

# Definicija

Naj bo G dopustna kontekstno-neodvisna gramatika. Definiramo preslikavo  $f_G^\infty: (V \cup \Sigma)^* \to (V \cup \Sigma)^*$ , ki vsak  $\alpha \in (V \cup \Sigma)^*$  preslika v fiksno točko D0L sistema  $(V \cup \Sigma, f_G^\infty, \alpha)$ .

Z  $\mathcal A$  označimo poljubno abecedo z vsaj dvema črk in fiksiramo končno mnogo množico simbolov

$${A_0, A_1, A_2, \ldots},$$

Predpostavimo, da nobeden od simbolov  $A_0, A_1, A_2, \ldots$  ne nastopa v abecedi A.

# Definicija

Naj bo  $\mathcal A$  abeceda. S $\mathcal G(\mathcal A)$  označimo pravo podmnožico vseh kontekstno neodivsnih gramatik G, ki izpolnjujejo naslednje pogoje:

• *G* je dopustna

# Definicija

Naj bo  $\mathcal{A}$  abeceda. S  $\mathcal{G}(\mathcal{A})$  označimo pravo podmnožico vseh kontekstno neodivsnih gramatik G, ki izpolnjujejo naslednje pogoje:

- G je dopustna
- $V(G) = \{A_0, A_1, A_2, \dots, A_{|V(G)|-1}\}$

# Definicija

Naj bo  $\mathcal{A}$  abeceda. S  $\mathcal{G}(\mathcal{A})$  označimo pravo podmnožico vseh kontekstno neodivsnih gramatik G, ki izpolnjujejo naslednje pogoje:

- *G* je dopustna
- $V(G) = \{A_0, A_1, A_2, \dots, A_{|V(G)|-1}\}$
- $\Sigma(G) \subset \mathcal{A}; S(G) = A_0$

# Definicija

Naj bo  $\mathcal{A}$  abeceda. S  $\mathcal{G}(\mathcal{A})$  označimo pravo podmnožico vseh kontekstno neodivsnih gramatik G, ki izpolnjujejo naslednje pogoje:

- G je dopustna
- $V(G) = \{A_0, A_1, A_2, \dots, A_{|V(G)|-1}\}$
- $\Sigma(G) \subset \mathcal{A}$ ;  $S(G) = A_0$
- ullet Če naštejemo nekončne simbole V(G) v vrstnem redu pojavitve v nizu

$$f_G^0(A_0)f_G^1(A_0)f_G^2(A_0)\dots f_G^{|V(G)|-1}(A_0),$$

dobimo urejen seznam  $A_0, A_1, A_2, \dots A_{|V(G)|-1}$ 

#### Definicija

Naj bo  $\mathcal A$  abeceda. Z  $\mathcal G^*(\mathcal A)$  označimo pravo podmnožico množice  $\mathcal G(\mathcal A)$  za katero velja, da za vsaka nekončna simbola  $A,B\in V(G),\ A\neq B$  velja

$$f_G^{\infty}(A) \neq f_G^{\infty}(B)$$
.

## Definicija

Naj bo  $\mathcal A$  abeceda in G kontekstno-neodvisna gramatika. Preobrazba niza je preslikava

$$\mathcal{A}^+ \to G^*(A),$$
  
 $x \mapsto G_x.$ 

# Definicija

Naj bo  $\mathcal A$  abeceda in G kontekstno-neodvisna gramatika. Preobrazba niza je preslikava

$$A^+ \to G^*(A),$$
  
 $x \mapsto G_x.$ 

Z |G| označimo skupno število vseh desnih članov produkcijskih pravil gramatike vključno s ponovitvami. Preobrazba niza je asimptotsko kompaktna, če je

$$\lim_{n\to\infty} \max_{x\in\mathcal{A}^n} \frac{|G_x|}{|x|} = 0.$$

# Biskecijska preobrazba niza

# Definicija

Naj bo  $x = x_1 x_2 \cdots x_n \in \mathcal{A}^+$ . Vpeljemo *bisekcijsko členitev niza* 

$$S(x) = \{x\} \cup \{x_i \cdots x_j \mid \frac{i-1}{j-i+1} \text{ in } \}.$$